

Анализ данных на практике

Линейная классификация

Виктор Кантор

Линейная классификация

- Идея линейной классификации
- Функции потерь
- Градиентный спуск и стохастический градиент
- Регуляризация
- Стандартные линейные классификаторы


Идея линейной классификации

$$a(x) = \text{sign}\{f(x)\}$$

$f(x)$ — дискриминантная функция

$$f(x) = \langle w, x \rangle + w_0$$

Геометрическая интерпретация:
разделяющая гиперплоскость



Отступ (margin)

Отступом алгоритма $a(x) = \text{sign}\{f(x)\}$ на объекте x_i называется величина $M_i = y_i f(x_i)$ (y_i - класс, к которому относится x_i)

$$M_i \leq 0 \Leftrightarrow y_i \neq a(x_i)$$

$$M_i > 0 \Leftrightarrow y_i = a(x_i)$$

Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0]$$

Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$

Функция эмпирического риска




Функция потерь



Функция потерь


$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$



$$\begin{aligned} Q(M) &= (1 - M)^2 \\ V(M) &= (1 - M)_+ \\ S(M) &= 2(1 + e^M)^{-1} \\ L(M) &= \log_2(1 + e^{-M}) \\ E(M) &= e^{-M} \end{aligned}$$

Градиентный спуск

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n), \quad n \geq 0.$$



$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i)$$

$$\nabla \tilde{Q} = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$\frac{\partial M_i}{\partial w} = y_i x_i$$

$$\nabla \tilde{Q} = \sum_{i=1}^l y_i x_i L'(M_i)$$

$$w_{n+1} = w_n - \gamma_n \sum_{i=1}^l y_i x_i L'(M_i)$$

Стохастический градиент

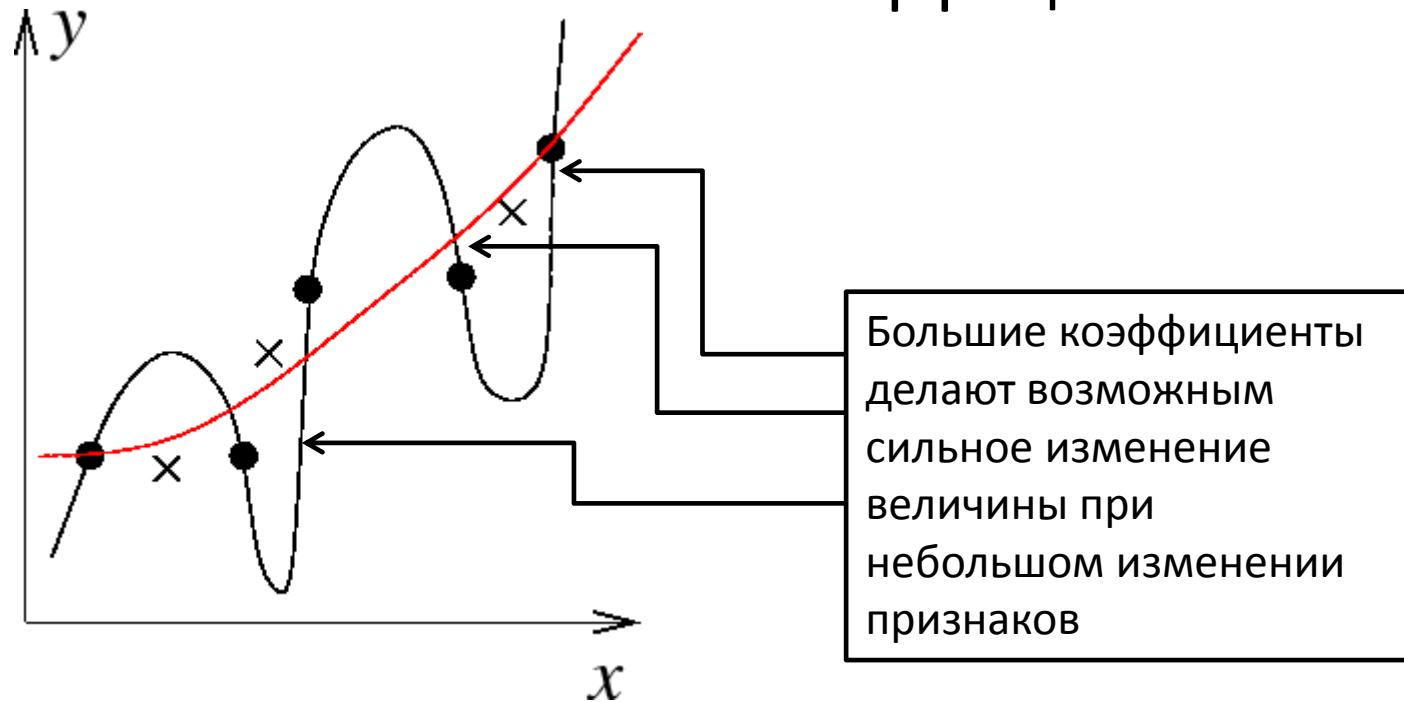
$$w_{n+1} = w_n - \gamma_n \sum_{i=1}^l y_i x_i L'(M_i)$$

$$w_{n+1} = w_n - \gamma_n y_i x_i L'(M_i)$$

x_i — случайный элемент обучающей выборки

Регуляризация

- Переобучение в задаче обучения с учителем как правило означает большие коэффициенты:




- Идея: добавить ограничение на коэффициенты

Регуляризация


$$\begin{cases} \tilde{Q} = \sum_{i=1}^l L(M_i) \rightarrow \min \\ \sum_{k=1}^m |w_k| \leq \tau \end{cases}$$

l1 – регуляризация



$$\begin{cases} \tilde{Q} = \sum_{i=1}^l L(M_i) \rightarrow \min \\ \sum_{k=1}^m w_k^2 \leq \tau \end{cases}$$

l2 – регуляризация




Регуляризация


$$\sum_{i=1}^l L(M_i) + \gamma \sum_{k=1}^m |w_k| \rightarrow \min$$

$$\sum_{i=1}^l L(M_i) + \gamma \sum_{k=1}^m w_k^2 \rightarrow \min$$

$l1$ – регуляризация




$l2$ – регуляризация



Различия между l_1 и l_2

- **Разреженность** – l_1 -регуляризация делает вектор весов более разреженным (содержащим больше нулей)
- В случае линейной классификации это означает **отбор признаков**: признаки с нулевыми весами не используются в классификации
- Простая геометрическая иллюстрация разреженности:



Стандартные линейные классификаторы

Классификатор	Функция потерь	Регуляризатор
SVM (Support vector machine, метод опорных векторов)	$L(M) = \max\{0, 1 - M\}$	$\sum_{k=1}^m w_k^2$
Логистическая регрессия	$L(M) = \log(1 + e^{-M})$	Обычно $\sum_{k=1}^m w_k^2$ или $\sum_{k=1}^m w_k $
LDA (Линейный дискриминантный анализ/линейный дискриминант Фишера)	$L(y, f(x)) = (y - f(x))^2$ $y \in \left\{-\frac{l}{l_-}, +\frac{l}{l_-}\right\}$	$\sum_{k=1}^m w_k^2$ в случае плохой обусловленности


Бонусные слайды

SVD = Singular Vector Decomposition
(сингулярное разложение матриц)


Позволяет получить наилучшее приближение исходной матрицы X матрицей X' ранга k .

Применяется для снижения размерности пространства признаков.

SVD



SVD: пример




SVD: пример



SVD: пример



Геометрический смысл SVD



$$M = U \cdot \Sigma \cdot V^*$$

Итог

- Идея линейной классификации
- Функции потерь
- Градиентный спуск и стохастический градиент
- Регуляризация
- Стандартные линейные классификаторы